

解説

機械学習，数理的手法による TSSG-SiC 結晶成長の最適条件予測

竹原悠人¹・岡野泰則^{1*}

Optimization of TSSG-SiC crystal-growth conditions using machine learning and mathematical method

Yuto Takehara¹ and Yasunori Okano^{1*}

Artificial intelligent including machine learning is promising for a new tool for the novel optimization in various industrial fields. In this article, we introduce our recent results on the optimization of crystal growth of SiC by RF-TSSG by using machine learning and a nonparametric mathematical optimization method. The results show that they must be a powerful tool for the determination of optimum crystal growth condition such as crystal rotation rate, strength of magnetic field and temperature distribution along crucible wall.

1. 緒言

かつて state-of-arts と呼ばれた結晶成長は，観察技術，測定技術や数値流体力学（CFD）の著しい発展に伴い，Science and Engineering へと大幅な発展を遂げてきている．特に近年の高度な CFD により，結晶成長時の流動，熱・物質移動現象およびそれらに及ぼす磁場や回転などの外力印加の影響はほぼ明らかにはなっている．しかしながら高温物性値が不明な物質や新たな物質の作製および高品質化には未だ多くの経験と勘が重要であるのも現状である．特に数ある結晶成長パラメータの最適な組み合わせの選択は CFD を用いても多大な時間とコストを有する作業である．

これに対し近年，実験や数値解析に代わり，既有データから解析を行うデータ科学が注目を集めている．機械学習，人工知能（AI）もこのデータ科学の一部であり，現在，急速な発展とともに様々な分野での適用が始まっている．それにより作業の自動化や，画像認識による入退場の高速化などが実現される．この流れは結晶成長プロセスにおいても例外ではなく，機械学習を結晶成長に適用する研究¹⁻³⁾が報告されている．機械学習の適用により試行錯誤を極力減らした少ない回数での実験や数値計算が可能となる．そしてそれにより結晶成長条件の最適化が実現でき，時間や費用の大幅な削減につながる事が期待される．結晶成長には結晶成長速度，結晶品質などを大きく左右するパラメータが数多く存在し，お互いが密接に絡んでいる．このパラメータ数が多いことと，それらの従属性ゆえに，現象の解明が困難であり最適化も同様に非常に困難となっている．筆者らはこの最適化問題に機械学習を用いることで効率よく最適化することに挑戦している．しかしながら，データ科学はデータ量がその精度に大きく依存しており，データ量が不足している状況では正確な解析をすることができない．そして必要となるデータ量はパラメータの増加とともに指数関数的に増加する．データの収集が容易であれば良いが，不幸なことに結晶成長において膨大なデータ量を得ることは時に困難である．そのため，機械学習だけではなくデータ量に依存しない最適化を考える必要がある．本解説ではパラメータが 10 個程度までの際に有用である機械学習による最適化と，パラメータ数に依存しない数理的最適化手法について Top-Seeded Solution Growth (TSSG) 法によるシリコンカーバイド（SiC）結晶成長を例に解説を行う．

1 大阪大学大学院基礎工学研究科物質創成専攻 560-8531 大阪府豊中市待兼山町 1-32

1 Department of materials Engineering Science, Graduate School of Engineering Science, Osaka University, Machikaneyama 1-3, Toyonaka, Osaka, 560-8531, Japan

* Corresponding Author E-mail: okano@cheng.es.osaka-u.ac.jp

1.1 TSSG 法を用いた SiC 結晶成長

シリコンカーバイド（SiC）は幅広いバンドギャップ，高い熱伝導率といった優れた性能を持つことから次世代パワー半導体として注目が集まっている．現在パワー半導体として主に用いられているシリコン（Si）と比較すると，6H SiC の場合，バンドギャップは約 2 倍，熱伝導率は約 3 倍である⁴⁾．欠陥の少ない高品質 SiC 単結晶を得る方法として Top-Seeded Solution Growth（TSSG）法が挙げられる．TSSG 法の装置図を Fig. 1 に示す．本法では，炭素から成るつぼ（Crucible）内に固体のケイ素を入れ，電磁場コイルによる誘導加熱によりつぼを加熱しケイ素を融解させる．そしてつぼから炭素が溶け出すことで結晶成長に必要な炭素がケイ素溶液（Solution）に供給される．この炭素が溶液表面に取り付けられた種結晶（Seed）に運ばれることにより種結晶上で過飽和となり結晶が成長する．高温ゆえ実験中はつぼ内の Si-C 成長溶液，結晶成長の様子を直接観察することは極めて困難である．さらに溶液内はコイルによる電磁場対流，自由表面上での界面張力差によるマランゴニ対流，浮力差による自然対流が発生し，複雑な輸送現象を形成している．そのため溶液内対流を安価に可視化することのできる数値解析を用いた研究は有用であり，盛んに行われている⁵⁻¹²⁾．これまでの研究により，Fig. 1 に示す装置配置では種結晶の下でマランゴニ対流が支配的となることが判明している¹³⁾．マランゴニ対流は自由表面上で種結晶へと向かう流れであり，この流れはそのまま種結晶の下へと流れ込む下降流となる．この下降流により種結晶への炭素の輸送が不均一となり，結晶成長速度の低下と不均一化が引き起こされる．これは通常の引き上げ法とは異なる現象であり，これまで引き上げ法で培ってきた技術に加え，マランゴニ対流の制御手法の開発が高品質結晶成長技術の構築に必須であるということを示唆する．以下に紹介する最適化手法では，このマランゴニ対流を抑制し，結晶成長速度の上昇と均一化を同時に達成することを目的とする．最適化する初期状態は最大電流密度 $6.285 \times 10^6 \text{ Am}^{-2}$ の交流電流を周波数 25kHz でコイルに流している状況で，十分に溶液内対流が発達した状態を選択した．ただし最適化手法の都合上，2 章では非定常解析，3 章では定常解析により得られた結果を用いている．用いている数値解析については論文^{8, 10, 12)}に詳しく記述されている．




Fig. 1 The configuration of the TSSG method (left) and the zoomed domain of the solution (right).

2. 機械学習

機械学習の精度は学習するデータの量に大きく依存する．そのため，データの取得が困難な場合については予測モデルの構築に時間と労力を有する．ここでは効率よく学習するデータを収集しながら最適化を行うベイズ最適化の適用について解説する．ベイズ最適化は目的が達成される可能性を表す指標として獲得関数というものを導入する．そして既存のデータセットを用いて回帰を行い，その獲得関数の値が高くなるパラメータを算出しながらデータ収集と学習を繰り返すため，効率の良い最適化が可能となる．つまり目的が達成されそうにないパラメータに関してはデータの収集を行わない．一方これはデータが存在しない未知領域が必ず生まれることを意味しており，その結果，最適化の収束判定が困難になるという問題点もある．

2.1 ベイズ最適化の手順

最適化を行うパラメータを $\mathbf{x}$ ，目的関数を $y = f(\mathbf{x})$ とする．パラメータの変更により目的関数の最大化，または最小化を行うことで最適化する．最大化と最小化は目的関数の符号を変えることで同様に達成されるので，本章では最大化を例に解説する．ベイズ最適化による最適化の流れは以下の通りである．

1. 回帰用初期データセットを作成する．
2. ガウス過程回帰により予測分布を得る．
3. 獲得関数を用いて，目的が達成される可能性の高いパラメータを算出する．

4. 3で得られたパラメータにおける実験または数値解析を行う。
5. 得られた結果を初期データセットに追加する。
6. 2に戻る。

ここで初期データセットのデータ数はいくつでもよい。1つのデータからでも行うことが可能であるが、推奨はされない。Step2で使用されるガウス過程回帰は教師あり学習のひとつである。ガウス過程回帰は各データが対応するパラメータに対してガウス分布に従うことを仮定して行うものである。そのため予測分布も同様にガウス分布の形で得られ、予測の期待値（平均値） μ と標準偏差 σ により表される。標準偏差からは予測の粗さを求めることができる。Fig. 2に例として $y = 5\cos(x)$ とした場合のガウス過程回帰を示した。Fig. 2中の青線は予測の期待値 μ を、薄い青色の幅は予測の95%信頼区間 2σ を表している。赤色の曲線は例として1つのパラメータの値に対するガウス分布を表している。このようにパラメータすべての値に対してガウス分布を求め、平均値をつないだものが青い線、95%信頼区間をつないだものが薄い青色の幅になる。ガウス過程回帰の詳細な導出や説明は成書¹⁴⁾に詳しく説明されてあるので参照されたい。




Fig. 2 Gaussian process regression. The blue line and blue bound show the expectation value and the confidence bound of the prediction, respectively. The red curve is the Gaussian distribution at the point.

Step 3で使用される獲得関数とは Step 2で得られた予測分布をもとに、次に実験または数値解析を行うパラメータ $\mathbf{x}_{\text{next}}$ を決定する戦略を定める関数である。獲得関数は有名なもので以下の3つがあげられる。

i) Probability of Improvement (PI)

目的関数の値を改善する確率が最も高いものを $\mathbf{x}_{\text{next}}$ として選択する戦略。

ii) Expected Improvement (EI)

目的関数の値を改善する期待値が最も高いものを $\mathbf{x}_{\text{next}}$ として選択する戦略。

iii) Upper Confidence Bound (UCB)

目的関数の予測分布において信頼区間の上限が最も高いものを $\mathbf{x}_{\text{next}}$ として選択する戦略。

一般的に上記の中ではEIが最も良い結果を与えることが知られている¹⁵⁾。

2.2 結晶成長条件の最適化

Cz法におけるSiの結晶成長では溶液部分に種々の磁場の印加、種結晶の回転を行うことで、対流を制御し、結晶品質の向上を行うことが出来る。筆者らは数値解析を用いてこの技術をTSSG法におけるSiCの結晶成長に適用した場合の効果について検討した。その結果、Cz-Si結晶成長時と同様に、磁場の印加と種結晶の回転を行うことで、対流の制御が可能となりSiC結晶の品質向上を見込めることが分かった¹⁰⁾。その中でも筆者らは特にこれまでSiCでは検討されてこなかったカスプ磁場の効果に関し上記のベイズ最適化を用いて磁場と回転に関するパラメータの最適化を行い、最適な結晶成長条の提案を行った¹⁰⁾。その結果、パラメータの全組み合わせ数に対して約1/4の計算回数で最適なパラメータの値を提案することが出来た。得られた結果について詳しく解説する前に、最適化を行ったカスプ磁場、種結晶の回転とそれらのパラメータ、さらに目的関数について説明する。TSSG法によるSiC結晶成長においてマランゴニ対流が問題であることは先に述べたが、論文¹⁰⁾により、溶液部分にカスプ状磁場 $\mathbf{B} = B_0 [r, 1, 2(z-H_0)] / Rc$ を印加し、種結晶を回転させる（Fig. 3）ことでマランゴニ対流を抑制しうることが報告されている¹⁰⁾。座標の原点はFig. 3に示すように種結晶の中心でかつ種結晶が溶液表面と接する点とした。




Fig. 3 The cusp magnetic field (blue line) and seed rotation (orange arrow).

磁場は溶液内にローレンツ力を発生させることで対流を抑制する作用があり，種結晶の回転はくみ上げ効果により，種結晶下で上昇流を作る作用がある．その結果，種結晶への炭素の供給が均一になり結晶成長速度を上げ，均一にする働きとなる．しかし，現象が非定常であるため数値計算コストが高く，パラメータの値の組み合わせ数も多いことから最適条件の提案には至っていなかった．そこで今回は最適化するパラメータとして以下に示すカスプ状磁場の強さ B_0 ，カスプ中心の z 座標 H_0 ，種結晶の回転速度 Ω の3つを選び，最適条件の設定を試みた．

$$\mathbf{x} = (B_0, H_0, \Omega)$$

また最適化するパラメータはすべて5段階の離散変数として，その取りうる値を Table 1 に示した．

Table 1 The range of the parameters.

B_0 [T]	H_0 [mm]	Ω [rpm]
0	0	0
0.05	5	20
0.1	10	40
0.15	15	60
0.2	20	80

最大化を行う目的関数 f を以下のように定義した．

$$f = \frac{M_{\text{gr}}}{M_0} - \frac{\sigma_{\text{gr}}}{\sigma_0} = M^* - \sigma^*$$

ここで， z 軸方向の結晶成長速度を $v_g(r)$ として以下の関係がある．ただし r は半径方向座標を表す．

$$v_g(r) = \frac{DM_{\text{SiC}}}{\rho_{\text{SiC}}} \mathbf{n} \cdot \nabla c(r) \Big|_{\text{seed}}$$

$$M_{\text{gr}} = \frac{\int_{C_{\text{Tar}}} v_g(r) dC}{\int_{C_{\text{Tar}}} dC}, \quad \sigma_{\text{gr}} = \sqrt{\frac{\int_{C_{\text{Tar}}} \{v_g(r) - M_{\text{gr}}\}^2 dC}{\int_{C_{\text{Tar}}} dC}}$$

$$M_0 = M_{\text{gr}} \Big|_{B=\Omega=0}, \quad \sigma_0 = \sigma_{\text{gr}} \Big|_{B=\Omega=0}$$





Fig. 4 The target region of the Bayesian optimization.

ここで、 D は炭素の拡散係数、 M_{SiC} は SiC のモル質量、 ρ_{SiC} は SiC の密度、 $\mathbf{n}$ は種結晶界面に対して垂直方向の単位ベクトル、 c は炭素の濃度、 C_{tar} は種結晶上の 0—4 mm の線分、 dC は線積分を表す。 M_{gr} 、 σ_{gr} はそれぞれ結晶成長速度の平均値、標準偏差すなわち成長速度のばらつきを表す。これをカスプ状磁場と種結晶の回転を適用しなかった場合（最適化前）の値で除すことにより無次元化したもの M^* 、 σ^* の差として目的関数を設定した。目的関数の最大化を行うことで結晶成長速度の平均値の最大化を行いながら、成長速度のばらつきの最小化を同時に行うことが出来る。結晶端ではマランゴニ対流により結晶成長速度が非常に不均一になることから、結晶端を除いた 0—4 mm を最適化対象領域とした（Fig. 4）。ベイズ最適化の結果を Fig. 5 に示す。Fig. 5 の左図は横軸に結晶成長速度の標準偏差 σ^* 、縦軸に平均値 M^* をとったもので目的関数 f がこれらの差で表されることから図上の左上が高い f 、右下が低い f の値を表す。青のプロットは Table 1 が示すパラメータの値の全組み合わせの数値解析結果であり、黄色のプロットはそのうちベイズ最適化により計算が行われた点である。黒い×印はベイズ最適化を行う際の初期データセットである。これよりベイズ最適化では最適条件（点 A）が求められており、目的関数の値が高い点を重点的に探索していることがわかる。点 A におけるパラメータは $\mathbf{x} = (0.05 \text{ T}, 15 \text{ mm}, 80 \text{ rpm})$ であった。この結果を得るために必要な計算回数はパラメータの全組み合わせ数 125 通りのうち、初期データセットを含めてわずか 36 回であり、約 1/4 の計算回数で最適解とその周辺の解を求めることができた。Fig. 5 の右図は最適化前（initial）と後（optimal）の結晶成長速度を示している。図からわかるように最適条件では対象領域（0—4 mm）において、均一で高い結晶成長速度が得られていることがわかる。

Fig. 5 The map of M^* vs σ^* (left) and the crystal growth rates of the initial and optimal states (right)¹⁶⁾.

次に最適条件における溶液内対流を Fig. 6 に示す。Fig. 6 から種結晶下では下降流を発生させるマランゴニ対流が抑制され、上昇流となっていることがわかる。このようにしてベイズ最適化により、マランゴニ対流を抑制する条件を得ることができた。Fig. 5 より最適化対象領域で 400 $\mu\text{m/h}$ という最高結晶成長速度が得られている。この速度の大きさから、3h 程度の結晶成長では結晶の変形の影響をほぼ無視することができ、Fig. 6 と同じ濃度、温度、速度分布が得られると考えられる。




Fig. 6 The temperature, concentration, and velocity fields in the solution of the initial (left) and optimal (right) states¹⁶⁾.

3. 逆解析

数値解析，機械学習が入力から出力を得る順方向の解析であるのに対して，逆解析は出力から入力を推定する逆方向の解析を指す（Fig. 7）．本章では逆解析のひとつである随伴変数法を結晶成長に適用した例を紹介する．随伴変数法は最適化するパラメータの数に依存しないノンパラメトリックな最適化が可能である．そのため最適化するパラメータが膨大である場合や，分布（無限自由度）を持つ場合に非常に有力である．しかし数理的最適化ゆえに実験にそのまま適用するには工夫が必要となる．




Fig. 7 The image of the machine learning and inverse analysis.

3.1 随伴変数法

随伴変数法は変分法を用いることで入力パラメータ $\mathbf{x}$ の変化に対する目的関数 F の変化（感度） $\delta F / \delta \mathbf{x}$ を求める手法である．本章では目的関数の最小化問題について記す．現象を記述する支配方程式とラグランジュの未定乗数法から得られる随伴方程式を解くことで，入力パラメータの感度を1回の数値解析により求めることができる．その際，パラメータの数にかかわらず全パラメータの感度を求めることが出来る．そのためノンパラメトリックな最適化が実現される．以下に随伴変数法の手順を示す．

1. 支配方程式を解く．
2. 収束判定を行う．（未収束の場合は3へ）
3. 随伴方程式を解く．

4. 感度を計算する.
5. 感度に従ってパラメータを変更する.
6. 1に戻る.

随伴変数法の詳細な解説は記事¹⁷⁾に詳しく書かれている．ここで随伴変数法概念図を Fig. 8 に示す．




Fig. 8 The conceptual scheme of the adjoint method.

Fig. 8 のように目的関数の勾配（感度）を求め，勾配を下るようにパラメータを変更しながら最適化するのが随伴変数法である．Fig. 8 において点 A から最適化を行った場合と，点 B から最適化を行った場合で得られる最適解が異なることがわかる．このように随伴変数法には初期値依存性があり，局所的な最小値をもつ解（局所解）にとらわれる可能性がある．随伴変数法はこの初期値依存性に注意しなければならない．

3.1 随伴変数法の適用

随伴変数法を用いて，るつぼの温度境界条件を最適化することにより，温度という分布を持つ無限自由度のパラメータの最適分布を提案することが出来た¹⁸⁾．以下に設定した目的関数を示し，Fig. 9 に最適化を行う対象領域を示す．

$$F = \frac{\int_{\Gamma_{\text{tar}}} (-u_r) d\Gamma}{\int_{\Gamma_{\text{tar}}} d\Gamma}$$

Fig. 9 The target region of the adjoint method.

Γ_{Tar} は最適化を行う対象の境界（自由表面上の種結晶端からその先 1 mm）であり， $d\Gamma$ は自由表面上の面積分である．以上で定義した目的関数の最小化を行うことは，最適化対象境界で半径方向内向きの速度 $-u_r$ を最小化することを意味する．対象境界上で内向き流れを作るのはマランゴニ対流である．つまり目的関数を最小化することで，マランゴニ対流の抑制を行う．支配方程式，随伴方程式は論文¹⁶⁾に記されている．随伴変数法による目的関数の推移と最適化の結果を Fig. 10 および Fig. 11 に示す．




Fig. 10 Decreasing of the normalized objective function with respect to iteration = 0 ¹⁸⁾.




Fig. 11 The temperature field and velocity field under the seed of the optimal state (a), the temperature boundary conditions along the wall (b) and the bottom (c) of the crucible of the initial and optimal states and the crystal growth rates of the initial and optimal states (d) ¹⁸⁾.

Fig. 10 より目的関数は減少を続け、最適化が正常に行われていることが示されている。得られた最適温度境界条件は Fig. 11(b,c)の示す温度分布となった。このようにするつぼの温度境界条件を設定することで、結晶成長速度を 80%均一化することに成功した。また溶液内対流において種結晶の下では速さ小さいものの上昇流となっていることがわかる。これはマランゴニ対流が抑制された結果であり、随伴変数法により目的を達成することが出来た。

4. まとめ

結晶成長の最適条件の提案に対して、機械学習であるベイズ最適化、逆解析である随伴変数法を適用した結果を紹介した。ベイズ最適化では3つのパラメータを全組み合わせ数の約 1/4 の計算回数で最適なパラメータの提案をすることができ、随伴変数法では温度分布という無限自由度を持つパラメータの最適分布を提案することができた。両者ともマランゴニ対流を抑制し、目的である均一で高い結晶成長速度を達成した。本解説で紹介した二つの手法にはそれぞれ長所と短所が存在し、対象とする系に応じて適当に選択される必要がある。今後、特に機械学習は最適化のみならず多岐にわたって適用されることが予想される。

一方で本結果はあくまでも数値計算上の最適条件を提案するものであり，人為的な誤差を含む実際の結晶成長における最適条件を必ずしも言い当てるとは限らない．しかしながら少なくとも実験の初期条件の設定，特に本稿で紹介した TSSG 法に対するカスプ磁界印加といったこれまでに実験例の無い条件における実験条件の設定には有用なツールとなると確信する．

また本解説では最適条件の提案に成功した事例を紹介したが，もちろんうまく機能しない場合も存在する．それは機械学習にも限界があり，万能な手法ではないからである．このことを念頭に入れて，機械学習の限界と相談しながら適用方法を模索していかなければならない．また逆解析で算出した温度分布を実現する炉構造やコイル位置を探索する際に機械学習を用いるなど，両者を組み合わせることも有用であり，これらの解析を実験や CFD と組み合わせて用いていくことが重要である．

5. 引用文献

- 1) Y. Tsunooka, N. Kokubo, G. Hatasa, S. Harada, M. Tagawa, T. Ujihara: Cryst. Eng. Comm., **20** (2018) 6546.
- 2) N. Dropka and M. Holena: J. Cryst. Growth, **471** (2017) 53.
- 3) N. Dropka, M. Holena, S. Ecklebe, C. F. Rotsch and J. Winkler: J. Cryst. Growth, **521** (2019) 9.
- 4) H. Morkoc, S. Strite, G. B. Gao, M.E. Lin, B. Sverdlov, and M. Burns: J. Appl. Phys., **76** (1994) 1363.
- 5) F. Mercier, J. Dedulle, D. Chaussende and M. Pons: J. Cryst. Growth, **312** (2010) 155.
- 6) J. Lefebure, J. Dedulle, T. Ouisee and D. Chaussende: Cryst. Growth Des., **12** (2012) 909.
- 7) K. Kusunoki, N. Okada, K. Kamei, K. Moriguchi, H. Daikoku, M. Kado, H. Sakamoto, T. Bessho and T. Ujihara: J. Cryst. Growth, **395** (2014) 68.
- 8) T. Yamamoto, Y. Okano, T. Ujihara and Sadik Dost: J. Cryst. Growth., **470** (2017) 75.
- 9) M. Ha, Y. Shin, M. Lee, C. Kim and S. Jeong: Phys. Status Solidi A, **215** (2018) 1701017.
- 10) L. Wang, T. Horiuchi, A. Sekimoto, Y. Okano, T. Ujihara and Sadik Dost.: J. Cryst. Growth, **498** (2018) 140.
- 11) L. Wang, T. Horiuchi, A. Sekimoto, Y. Okano, T. Ujihara and Sadik Dost.: J. Cryst. Growth, **520** (2019) 72.
- 12) T. Horiuchi, L. Wang, A. Sekimoto, Y. Okano, T. Yamamoto, T. Ujihara and Sadik Dost.: Cryst. Res. Technol., **54** (2019) 1900014.
- 13) T. Yamamoto, N. Adkar, Y. Okano, T. Ujihara and Sadik Dost: J. Cryst. Growth., **474** (2017) 50.
- 14) 持橋大地，大羽成征：ガウス過程と機械学習，(講談社，2019)．
- 15) J. Snoek, H. Larochelle and R. P. Adams: Adv. Neural Inf. Process Syst. **25** (2012) 2960.
- 16) Y. Takehara, A. Sekimoto, Y. Okano, T. Ujihara, S. Dost: J. Cryst. Growth. (submitted).
- 17) K. Momose and K. Ikejima: NEE研究会第 11 回講演討論会資料 (2007 年 1 月 19 日) ”随伴数値解析に基づく汎用熱対流場設計支援システムの開発”．
- 18) T. Horiuchi, L. Wang, A. Sekimoto, Y. Okano, T. Yamamoto, T. Ujihara and Sadik Dost.: J. Cryst. Growth, **517** (2019) 59.

6. 謝辞

本研究は名古屋大学，宇治原徹教授，大阪大学，関本敦助教との共同研究の成果に基づくものである．本研究は九州大学情報基盤研究開発機関の計算資源を使用して行った．また本研究の一部は科研費基盤研究 A (No. JP18H03839) の助成を受けた．

(2019 年 11 月 29 日受理)